

Маршрутизатор LLM: GPT, GigaChat и резервный маршрут

Разбираем готовый сценарий: что внутри и почему так

Цель и задачи урока

ЦЕЛЬ

Разобраться, как устроена автоматизация вокруг единого контракта данных, и научиться адаптировать её под свою задачу

ЗАДАЧИ

- 01 Понять, из чего собран маршрутизатор и почему нод именно столько
- 02 Настроить доступ к двум поставщикам с разной авторизацией
- 03 Прочитать, что происходит при сбое основной модели
- 04 Сравнить модели на своих данных и обосновать выбор

Задача, которую решает сценарий

ОБРАЩЕНИЕ КЛИЕНТА

«С карты списали депозит дважды: 400 евро и сразу ещё 400»



```
{  
  "category":      "оплата",  
  "urgency":       "высокая",  
  "summary":       "Двойное списание депозита",  
  "needs_human":   true,  
  "language":      "ru"  
}
```

10 обращений · 2 модели · 1 формат результата

Карта схемы

12 нод, три смысловые зоны

Подготовка

Настройки

Токен GigaChat

10 обращений

Работа

Какая модель?

GPT / GigaChat

Общая схема и проверка

Готово или попытки кончились?

Переключение на резерв

Результат

Итог

Отчёт

— Переключение на резерв возвращает заявку в ту же развилку

Настройки: единственное место для правок

primary_model	gpt	основная модель
fallback_model	gigachat	резервная модель
force_error_primary	false	переключатель демонстрации сбоя
max_tries	2	предел попыток
gpt_model	gpt-4o-mini	
giga_model	GigaChat	
system_prompt	общий промпт на обе модели	
price_gpt / price_giga	тарифы для расчёта стоимости	

Промпт лежит здесь в одном экземпляре и уходит в обе модели без изменений

Токен GigaChat: зачем отдельная нода

URL	ngw.devices.sberbank.ru:9443/api/v2/oauth
Auth	Header Auth → Authorization: Basic <ключ>
Headers	RqUID — обязательный идентификатор запроса
Body	scope = GIGACHAT_API_PERS физлицо
	scope = GIGACHAT_API_B2B юрлицо
Options	Ignore SSL Issues — сертификаты Минцифры

GigaChat работает по OAuth: ключ меняется на токен, токен живёт 30 минут

Тестовый набор: три служебных поля

```
{  
  request_id:      'R-001',  
  request_text:    'Хочу забронировать кабриолет...',  
  
  expected_category: 'бронирование',    эталон, проставлен человеком  
  model:            'gpt',              здесь живёт маршрут  
  attempt:          1,                  счётчик попыток  
}
```

`model` определяет маршрут

`attempt` не даёт петле стать
бесконечной

`expected_category` — разметка для
теста

Развилка одна на всю схему

```
{{ $json.model }} равно "gpt"
```

```
true → GPT
```

```
false → GigaChat
```

Резервный маршрут не получает собственную копию — он возвращается сюда же

Две ноды вызова: где кончается сходство

ПАРАМЕТР	GPT	GigaChat
Что это	штатная нода OpenAI	HTTP Request вручную
Ключ	креды OpenAI	токен из предыдущей ноды
Имя модели	By ID из настроек	из настроек в теле запроса
Строгий JSON	галочка Output as JSON	нет, только просьба в промпте
Сертификат	обычный	Ignore SSL Issues

Форма ответа при этом одинаковая: `choices[0].message.content` и `usage`

Три неочевидные настройки ноды GPT

Simplify Output	выключен
Output Content as JSON	включён
Model	By ID, а не From list

Simplify включён → нода выбрасывает usage → нечем считать стоимость

Output as JSON включён → слово «json» обязано быть в промпте строчными буквами

Model из списка → имя модели зашито в ноду, а не берётся из настроек

Error output: как падение превращается в ветку

Retry On Fail	✓
Max Tries	2
Wait Between Tries	1500 ms
On Error	Continue (using error output)

Без этой настройки первая же ошибка останавливает запуск — и никакого резерва не будет

Повтор — та же модель, лечит сеть и 429

Переключение — другая модель, только когда повторы не помогли

Адаптер: одна нода на двух поставщиков

01	Определить контекст	какая модель, какая заявка, эталон
02	Разобрать ответ	распаковать, снять markdown-обёртку
03	Нормализовать	таблицы соответствий
04	Проверить схему	<code>_valid</code> , <code>_fail_kind</code> , <code>_fail_reason</code>

Режим: Run Once for Each Item

Что чинит нормализация

МОДЕЛЬ ВЕРНУЛА

В СХЕМЕ

"booking"	→	бронирование
"Поломка и ДТП"	→	поломка
"Высокий"	→	высокая
"да"	→	true
```json {...}```	→	распакованный объект

transport — не дозвонились

format — пришло не JSON

schema — JSON не тот

Менять под свою задачу: список категорий и таблицы соответствий

## Условие выхода из петли

---

```
{{ $json._valid }} is true
```

ИЛИ

```
{{ $json.attempt }} ≥ max_tries
```

---

Комбинатор именно OR: либо контракт выполнен, либо попытки исчерпаны

Уберите второе условие — получите бесконечный круг и счёт за токены

## Переключение: меняется одно поле

```
model: d.model === 'gpt' ? 'gigachat' : 'gpt',
attempt: (d.attempt || 1) + 1,

_fallback_from: d.model,
_fallback_kind: d._fail_kind,
_fallback_reason: d._fail_reason,
```

---

### 24 ноды

резерв отдельной веткой

---

### 12 нод

резерв петлём

Маршрут должен быть данными, а не структурой схемы

## Итог и деградация

Когда не справилась ни одна модель:

```
category: "другое"
urgency: "высокая"
summary: "Автоклассификация не удалась, нужен ручной разбор"
needs_human: true
_meta.degraded: true
```

---

Заявка не теряется

---

Формат не меняется

---

Уходит человеку с пометкой

## Отчёт: шесть метрик

валидных_% <b>100</b>	полнота_полей_% <b>100</b>	совпадение_категории_% <b>90</b>
ошибки_формата_% <b>0</b>	среднее_время_мс <b>1576</b>	стоимость_руб <b>0.0827</b>

Вся арифметика в коде — ни один показатель не считает LLM

## Демонстрация сбоя

Настройки

→

`force_error_primary = true`

→

Run

ЧТО ПОЯВИТСЯ В ОТЧЁТЕ

переключений: 10

тип: transport

по_моделям: две строки вместо одной

причины: кто, куда, почему

Сбой вызывается подменой имени модели — честная ошибка от API, а не подмена результата

# Что сделать после импорта

1. Нода GPT

Credential → OpenAi account → sk-...
2. Нода Токен

Header Auth → Authorization: Basic <ключ Сбера>
3. Нода Токен

scope: PERS для физлица, B2B для юрлица
4. Нода Настройки

подставить свои тарифы

СИМПТОМ	ПРИЧИНА
400 на всех заявках GPT	нет слова «json» строчными в промпте
400 на токене GigaChat	RqUID пустой или нет scope в теле
403 на токене	scope не тот: PERS вместо B2B
Модель не та, что в настройках	поле Model стоит From list вместо By ID
Бесконечное выполнение	в условии выхода AND вместо OR
Стоимость в отчёте = 0	включён Simplify Output у ноды GPT

Ключи — только в кредитах, никогда в теле ноды

## Практическое задание

- 01 Импортировать сценарий, настроить оба доступа, прогнать 10 заявок
- 02 Включить `force_error_primary` — показать переключение и причину
- 03 Поменять `primary_model` на `gigachat`, прогнать снова, сравнить метрики
- 04 Заменить категории и таблицы соответствий на свои

### КРИТЕРИЙ ГОТОВНОСТИ

Обе модели дают одинаковую структуру · переключение работает · в отчёте есть причина · схема классифицирует ваши обращения

# Что прошли и что забрать с собой

единый контракт · нормализация типов и названий · `error output` и повторы · резерв как петля · ограничение попыток · три типа отказа · шесть метрик · критерии выбора модели

---

## 1. Маршрут должен быть данными, а не структурой схемы

Меняется поле `model` — не рисуется вторая половина холста

---

## 3. Отказ поставщика — штатная ветка, а не авария

Повтор → переключение → ручной разбор. Формат результата не меняется ни на одном шаге

---

## 2. Готовая нода не отменяет знания API

Половина ошибок настройки не объясняется интерфейсом вообще

---

## 4. Модель выбирают по своим данным

Чужие рейтинги — маркетинг. Свои десять заявок — основание. И даже они минимум, а не истина